

FIBRAS-mx

Experimento 2: Algoritmo

ML + Algoritmo Genético para Selección Óptima de FIBRAS

Autor:	Daniel Becerril Olguín
Fecha:	Mayo 2026
Stack:	Python 3.12 · Streamlit · scikit-learn · XGBoost · CatBoost · LightGBM
Datos:	2017-2026 · 15 FIBRAS · Frecuencia diaria
Páginas:	0_datos, 1_faqs, 2_estrategias, 3_algoritmo

Resumen ejecutivo

En lugar de codificar reglas de inversión manualmente (como E11 u E13), el Experimento 2 usa un Algoritmo Genético para descubrir qué combinación de features, modelo de ML e hiperparámetros maximiza el Sharpe del portafolio en 2017-2023, verificando que el resultado sea estadísticamente significativo en test (2024-2025) y holdout (2026).

El universo de búsqueda son 400 features (40 variables × 10 parametrizaciones) en 6 bloques: derivadas de estrategias existentes (A), fundamentales (B), técnicas (C), tendencia (D), mercado (E) y macro (F). El cromosoma incluye 1-5 genes, tipo de modelo, hiperparámetros, horizonte de predicción H y top-k.

1. Frecuencia de observaciones y partición de datos

Frecuencia: DIARIA — no solo trimestral

El dataset usa observaciones DIARIAS: ~26,250 filas en train (vs ~420 si usáramos solo rebalanceos trimestrales).

- Precios OHLCV: diarios → features técnicas calculadas día a día.
- Fundamentales trimestrales: forward-fill diario entre reportes. La ocupación del Q2 vale hacia adelante hasta que llega el Q3.
- Label: retorno futuro a horizonte H días. $H \in \{1, 5, 10, 21, 42, 63, 126\}$ — el GA descubre qué horizonte predice mejor.

Partición train / test / validation

Split	Período	Días hábiles	Obs. (días×15)	Propósito
Train	2017-01 → 2023-12	~1,750	~26,250	GA + ML
Test	2024-01 → 2025-12	~500	~7,500	Evaluación GA
Validation	2026-01 → hoy	~90	~1,350	Holdout real

Walk-forward CV dentro del train

Ventana expansiva, mínimo 252 días de historia, paso de 63 días (trimestral). Entrena en días $\leq t$, predice días $t+1$ a $t+H$.

Conexión con el rebalanceo trimestral

- Modelo entrenado con observaciones diarias.
- En cada fecha de rebalanceo Q, se predicen scores para los próximos H días.
- Se promedian los scores → ranking de FIBRAS → top-k elegidas.
- La ejecución sigue siendo trimestral (igual que E0-E13).

2. Universo de features: 40 variables × 10 params = 400 features

Bloque A — Variables de estrategias existentes (E0-E13)

ID	Variable	10 Parametrizaciones
A01	Retorno trailing	21d, 42d, 63d, 84d, 126d, 168d, 252d, 378d, 504d, 756d
A02	Log-retorno trailing	Mismos 10 horizontes que A01
A03	Volatilidad realizada	21d, 42d, 63d, 84d, 126d, 168d, 252d, 378d, 504d, ratio(21/252)
A04	Precio / MAN	MA20, MA30, MA50, MA60, MA100, MA120, MA150, MA200, MA250, MA300
A05	MAN > MAM (Golden Cross)	(20>50), (20>100), (50>100), (50>200), (20>200), (100>200), (30>100), (30>200), (60>150), (10>50)
A06	Fuerza relativa vs MA	Distancia % a MA50, MA100, MA200, sus negativos/invertidos + log
A07	Dividend yield TTM	raw, rank, >3%, >4%, >5%, >6%, >7%, >8%, >9%, top25%
A08	Precio / NAV	raw, rank, <0.80, <0.90, <0.95, <1.0, <1.05, <1.10, descuento%, rank_desc
A09	Ocupación	raw, rank, ≥0.75, ≥0.80, ≥0.85, ≥0.87, ≥0.90, ≥0.92, ≥0.95, QoQ-change
A10	FFO yield	raw, rank, >4%, >5%, >6%, >7%, >8%, >9%, >10%, anualizado×4
A11	Payout ratio (dist/FFO)	raw, rank, <0.60, <0.70, <0.75, <0.80, <0.90, <1.0, QoQ-change, inverted
A12	LTV ratio	raw, rank, <0.30, <0.35, <0.40, <0.45, <0.50, QoQ-change, inverted, >0.50
A13	Cambio Banxico 6M	raw, >+50bps, >+100bps, <-50bps, <-100bps, abs >50bps, dirección, aceleración, rolling12M, zscore
A14	Precio 30d mean	raw, rank, rank_top3, rank_top5, rank_top7, top50%, percentil, z-score, log, norm
A15	Sector dummy	industrial=1, hoteles=1, comercial=1, industrial+comercial, diversificado=1, no_hoteles=1, ponderado, mixto=1, 4 dummies

Bloque B — Variables Fundamentales (nuevas)

ID	Variable	10 Parametrizaciones
B01	NOI margin	raw, rank, >30%, >40%, >50%, >60%, >65%, QoQ-change, YoY-change, trend4Q
B02	Deuda / Activos	raw, rank, <0.35, <0.40, <0.45, <0.50, <0.55, QoQ-change, inverted, trend4Q
B03	Dilución de CBFIs	%change YoY, positivo, negativo, abs change, <1%, <3%, <5%, <-1%, <-3%, z-score
B04	Apreciación propiedades	%change YoY en appraised_value, rank, >0%, >2%, >5%, >8%, <0%, trend4Q, QoQ-change, zscore
B05	Distribución / Activos	dist×cbfis/total_assets, rank, >1%, >2%, >3%, >4%, >5%, trend4Q, QoQ-change, z-score

Bloque C — Variables Técnicas (nuevas)

ID	Variable	10 Parametrizaciones
C01	RSI	RSI-7, RSI-9, RSI-14, RSI-21, RSI-28, RSI-42, RSI-63, RSI<30, RSI>70, distancia-de-50
C02	Posición Bollinger	BB(20,2), BB(20,1.5), BB(50,2), %B(0-1), %B<0.2, %B>0.8, BB-width, BB-width-z, squeeze, inv-%B
C03	Z-score de volumen	z(21d), z(63d), z(126d), z(252d), >+1σ, >+2σ, <-1σ, tendencia, ratio(21/63), ratio(5/21)
C04	Precio / 52-week high	raw, >0.90, >0.95, >0.98, <0.80, <0.70, dist%, drawdown-52w, nuevo-máx(1/0), recuperación
C05	Amihud Illiquidity	ratio(21d), ratio(63d), ratio(252d), rank_liq, rank_iliq, thresh_high, thresh_low,

trend4Q, zscore, vs-sector

Bloque D — Variables de Tendencia (nuevas)

ID	Variable	10 Parametrizaciones
D01	Aceleración momentum	ret63-ret126, ret21-ret63, ret126-ret252, ret63/ret126, señal_pos, zscore, rank, 2da-deriv, negativa, norm
D02	Score multi-timeframe	0.25×ret21+0.25×ret63+0.25×ret126+0.25×ret252 + 8 combos de ponderaciones distintas + top25%
D03	Consistencia retornos	%días pos 21d, 63d, 126d, 252d, >50%, >60%, >70%, tendencia-mejora, zscore, rank
D04	EMA vs SMA (suavidad)	EMA21/SMA21, EMA50/SMA50, EMA vs SMA, >1(sube), <1(baja), distancia, ratio-cruzado, señal, z-score, rank
D05	Canal de precio	%channel(20d), %channel(63d), %channel(126d), >80%, >90%, <20%, <10%, breakout_up, breakout_dn, rango-norm

Bloque E — Variables de Mercado (nuevas)

ID	Variable	10 Parametrizaciones
E01	Fuerza relativa vs índice	ret - ret_index (21d, 63d, 126d, 252d), rank, >0%, >5%, >10%, zscore, rolling_rank, tendencia
E02	Momentum sectorial	avg_ret_peers (21d, 63d, 126d), fibra_vs_sector, sector_rank, top2, bottom2, spread, zscore, rank, tendencia
E03	Tendencia de volumen	slope(21d), slope(63d), slope(126d), >0%, >+20%, >+50%, ratio(5/15d), zscore, señal-pos, rank
E04	Correlación con IPC	corr_63d, corr_126d, corr_252d, <0.3, >0.7, beta_63d, beta_126d, beta_252d, tracking-error, corr-inversa
E05	Tamaño relativo	rank(top5), rank(top3), decil, tercil, log_price30d, cambio_rank_YoY, stable_large, concentración, peso_eq, peso_prop

Bloque F — Variables Macro (nuevas)

ID	Variable	10 Parametrizaciones
F01	Tasa real (Banxico-inf)	tasa-CPI_proxy, >5%, >6%, >7%, >8%, <4%, cambio_rate_real, zscore, rank, tendencia
F02	Spread yield-CETES	div_yield - CETES_28d, >0%, >1%, >2%, >3%, >4%, zscore, rank, tendencia-spread, spread_negativo
F03	Fase ciclo de tasas	subiendo(1/0), bajando(1/0), pausa(1/0), acelerando-suba, desacelerando-suba, cum_change_6M, velocidad, zscore, señal, dirección
F04	Tendencia USD/MXN	ret_usdmxn (21d, 63d, 126d, 252d), >0% peso-débil, <0% peso-fuerte, >+5%, <-5%, vol, corr-FIBRA, zscore
F05	Momentum IPC	ret_ipc (21d, 63d, 126d, 252d), >0%, >5%, >10%, <0%, zscore, rank_hist, tendencia, IPC>MA200(1/0), breadth_signal

3. Modelos de Machine Learning

#	Modelo	Hiperparámetros clave
1	Decision Tree	max_depth [2,3,4,5,6], min_samples_split [2,5,10,20]
2	Ridge Regression	alpha [0.01, 0.1, 1, 10, 100]
3	Logistic Regression	C [0.01, 0.1, 1, 10], solver [lbfgs, liblinear]
4	Random Forest	n_estimators [50,100,200], max_depth [2,3,4,5,None]
5	XGBoost	n_estimators [50,100,200], max_depth [2,3,4], lr [0.01,0.1,0.3]
6	CatBoost	iterations [50,100,200], depth [2,3,4], lr [0.01,0.05,0.1]
7	LightGBM	n_estimators [50,100,200], max_depth [2,3,4], lr [0.01,0.1]
8	Extra Trees	n_estimators [50,100,200], max_depth [2,3,4,None]
9	ElasticNet	alpha [0.01,0.1,1], l1_ratio [0.1,0.5,0.9]

Tarea ML: ranking con horizonte configurable

- El modelo predice un score continuo para cada FIBRA en cada día.
- Label: retorno a H días hacia adelante, normalizado 0-1 con rank entre las 15 FIBRAS.
- $H \in \{1, 5, 10, 21, 42, 63, 126\}$ — parte del cromosoma GA.
- En rebalanceo: promedio de scores últimos 63 días → top-k seleccionadas.
- $top_k \in \{3, 4, 5, 6, 7\}$ — también optimizable por el GA.

4. Encoding del cromosoma (GA)

```

Gene = namedtuple('Gene', ['var_id', 'param_idx'])
# var_id    : 0-39  (40 variables)
# param_idx : 0-9   (10 parametrizaciones)
# Total espacio de búsqueda: 400 genes posibles

@dataclass
class Individual:
    genes: list[Gene] # 1-5 genes, sin repetir var_id
    model_type: str    # uno de los 9 modelos
    model_params: dict # hiperparámetros del modelo
    horizon: int       # H días: in {1,5,10,21,42,63,126}
    top_k: int         # FIBRAS a seleccionar: in {3,4,5,6,7}
    fitness: float = -inf

```

5. Algoritmo Genético

Inicialización (20 individuos)

```

n_genes = random.choice([1, 2, 3, 4, 5])
genes = random.sample(ALL_400_GENES, n_genes) # sin repetir var_id
model_type = random.choice(MODELOS) # 9 opciones
params = random.choice(PARAM_GRID[model_type])

```

```
horizon = random.choice([1, 5, 10, 21, 42, 63, 126])
top_k   = random.choice([3, 4, 5, 6, 7])
```

Función de Fitness

```
fitness(ind):
```

1. Construir feature matrix DIARIA desde genes del individuo:
 - Features técnicas: día a día desde precios OHLCV
 - Features fundamentales: forward-fill de datos trimestrales
 - Label: retorno a ind.horizon días (rank 0–1 entre FIBRAS)
2. Walk-forward CV (ventana mín 252 días, paso 63 días):

Para cada fold t en [2017+252d ... 2023-12-31]:

 - Entrenar model(params) en días $\leq t$
 - Predecir scores diarios para [t+1 ... t+ind.horizon]
 - Agregar scores por FIBRA (promedio)
 - Seleccionar top_k FIBRAS
 - Calcular retorno portfolio (igual peso)
3. Calcular Sharpe de la serie de retornos de portfolio
4. Parsimony penalty: $-0.02 \times (n_genes - 1)$
5. Retornar Sharpe ajustado

Operadores evolutivos

Selección: Torneo de tamaño 3. Elitismo: top-2 pasan directamente.

Cruzamiento:

```
gene_pool = union(parent1.genes, parent2.genes)
n_child   = random.choice([1..5])
child_genes = random.sample(gene_pool, min(n_child, len(pool)))
child_model = random.choice([p1.model_type, p2.model_type])
child_params = mezcla de parámetros de ambos padres (por key)
child_horizon = random.choice([p1.horizon, p2.horizon])
child_top_k   = random.choice([p1.top_k, p2.top_k])
```

Mutación (P=0.3 por tipo, independientes):

- mutate_add: agregar un gene aleatorio (si $n < 5$)
- mutate_remove: eliminar un gene aleatorio (si $n > 1$)
- mutate_swap: reemplazar un gene por uno nuevo (distinto var_id)
- mutate_param: cambiar param_idx de un gene existente
- mutate_model: cambiar model_type y/o model_params (P=0.2)
- mutate_horizon: cambiar horizonte H (P=0.2)

Criterios de parada

- max_generations = 50 (configurable en UI, slider 10–100)
- Early stopping: sin mejora en el mejor fitness por 10 generaciones
- Re-diversificación: si >80% de la población es idéntica, reiniciar 40% (immigration)

6. Estructura de archivos

```
src/
  features/
    registry.py      # FEATURE_REGISTRY: dict[int, FeatureDef]
    builder.py       # build_feature_matrix(genes, ...) -> DataFrame
  genetic/
    chromosome.py    # Gene, Individual dataclasses
    operators.py     # crossover(), mutate(), tournament_select()
    fitness.py       # evaluate_individual(ind, ...) -> float
    ga.py            # run_ga(config) -> GAResult
  ml/
    models.py        # MODEL_REGISTRY: instanciar modelo por tipo+params
    cross_val.py     # walk_forward_cv(...) -> List[float]
  app/pages/
    3_algoritmo.py   # Streamlit página completa
  results/
    ga_results.pkl   # Cache del resultado del GA
```

7. Página Streamlit (3_algoritmo.py)

Sección 1 — Panel de configuración

- Generaciones: slider 10-100 (default 50)
- Tamaño de población: slider 10-50 (default 20)
- Modelos a incluir: multiselect (todos por default)
- k FIBRAS a seleccionar: slider 3-7 (default 5)
- Botón ▶ Correr GA] con spinner de progreso por generación
- Botón [Cargar último resultado] desde results/ga_results.pkl

Sección 2 — Resultados del GA (4 tabs)

Tab 1 — Convergencia

Gráfica fitness del mejor individuo y media poblacional vs. generación. Tabla top-5 individuos de la última generación.

Tab 2 — Mejor cromosoma

Tabla de features seleccionadas: bloque, variable, parametrización. Modelo ML + hiperparámetros. Feature importance si disponible (RF, XGB, LGB).

Tab 3 — Equity curve

3 líneas: Train (2017-2023), Test (2024-2025), Validation (2026). Comparativa vs E0 y E13. Métricas: CAGR, Sharpe, MaxDD por período.

Tab 4 — Comparativa 9 modelos

Para el mejor feature set, tabla de los 9 modelos: Sharpe_train, Sharpe_test, CAGR_train, CAGR_test, MaxDD_test. Celda ganadora resaltada en verde.

Sección 3 — Análisis de variables

- Barras: frecuencia de cada variable en el top-10 de individuos finales.
- Scatter: param_idx elegido vs fitness (¿hay umbrales preferidos?).
- Tabla: variables nunca seleccionadas (candidatos a eliminar del registro).

8. Orden de implementación

1. src/features/registry.py — definir las 400 features (funciones compute)
2. src/features/builder.py — build_feature_matrix()
3. src/ml/models.py + cross_val.py — MODEL_REGISTRY + walk_forward_cv()
4. src/genetic/chromosome.py — Gene, Individual
5. src/genetic/operators.py — crossover, mutate, select
6. src/genetic/fitness.py — evaluate_individual()
7. src/genetic/ga.py — run_ga()
8. app/pages/3_algoritmo.py — página Streamlit completa
9. Actualizar requirements.txt (xgboost, catboost, lightgbm)
10. Smoke test: 3 generaciones x 5 individuos → sin errores

9. Verificación

```
conda activate fibras-mx

# Smoke test GA rápido (3 gen x 5 individuos)
python -c "
from src.features.builder import build_feature_matrix
from src.genetic.ga import run_ga
result = run_ga(n_generations=3, population_size=5)
print('Mejor Sharpe train:', result.best_individual.fitness)
print('Genes:', result.best_individual.genes)
print('Modelo:', result.best_individual.model_type)
print('Horizonte H:', result.best_individual.horizon)
"

# Verificar en Streamlit
streamlit run app/main.py
# -> Nueva pestaña 'Algoritmo' en sidebar
# -> Botón 'Correr GA' -> spinner -> gráficas de convergencia
```